

Практическое задание №1

Установка необходимых пакетов:

In []:

```
!pip install -q tqdm
!pip install --upgrade --no-cache-dir gdown
```

```
Looking in indexes: https://pypi.org/simple, https://us-python.pkg.dev/colab-wheels/public/simple/
Requirement already satisfied: gdown in /usr/local/lib/python3.7/dist-packages (4.4.0)
Collecting gdown
  Downloading gdown-4.5.4-py3-none-any.whl (14 kB)
Requirement already satisfied: beautifulsoup4 in /usr/local/lib/python3.7/dist-packages (from gdown) (4.6.3)
Requirement already satisfied: six in /usr/local/lib/python3.7/dist-packages (from gdown) (1.15.0)
Requirement already satisfied: tqdm in /usr/local/lib/python3.7/dist-packages (from gdown) (4.64.1)
Requirement already satisfied: requests[socks] in /usr/local/lib/python3.7/dist-packages (from gdown) (2.23.0)
Requirement already satisfied: filelock in /usr/local/lib/python3.7/dist-packages (from gdown) (3.8.0)
Requirement already satisfied: chardet<4,>=3.0.2 in /usr/local/lib/python3.7/dist-packages (from requests[socks]->gdown) (3.0.4)
Requirement already satisfied: certifi>=2017.4.17 in /usr/local/lib/python3.7/dist-packages (from requests[socks]->gdown) (2022.9.24)
Requirement already satisfied: idna<3,>=2.5 in /usr/local/lib/python3.7/dist-packages (from requests[socks]->gdown) (2.10)
Requirement already satisfied: urllib3!=1.25.0,!>=1.25.1,<1.26,>=1.21.1 in /usr/local/lib/python3.7/dist-packages (from requests[socks]->gdown) (1.24.3)
Requirement already satisfied: PySocks!=1.5.7,>=1.5.6 in /usr/local/lib/python3.7/dist-packages (from requests[socks]->gdown) (1.7.1)
Installing collected packages: gdown
  Attempting uninstall: gdown
    Found existing installation: gdown 4.4.0
    Uninstalling gdown-4.4.0:
      Successfully uninstalled gdown-4.4.0
Successfully installed gdown-4.5.4
```

Монтирование Вашего **Google Drive** к текущему окружению:

In []:

```
from google.colab import drive
drive.mount('/content/drive', force_remount=True)
```

Mounted at /content/drive

Константы, которые пригодятся в коде далее, и ссылки (**gdrive** идентификаторы) на предоставляемые наборы данных:

In []:

```
EVALUATE_ONLY = True
TEST_ON_LARGE_DATASET = True
TISSUE_CLASSES = ('ADI', 'BACK', 'DEB', 'LYM', 'MUC', 'MUS', 'NORM', 'STR', 'TUM')
DATASETS_LINKS = {
    'train': '1XtQzVQ5XbrfxpLHJuL0XBGJ5U7CS-cLi',
    'train_small': '1qd45xXfDwdZjktLFwQb-et-mAaFeCzOR',
    'train_tiny': '1I-2ZOuXLd4QwhZQqltp817Kn3J0Xgbui',
    'test': '1RfPou3pFKpuHDJZ-D9XDFzgvwpUBF1Dr',
    'test_small': '1wbRsog0n7uGlHIPGLhyN-PMET2kdQ2lI',
    'test_tiny': '1viiB0s041CNSAK4itvX8PnYthJ-MDnQc'
```

```
}
```

Импорт необходимых зависимостей:

In []:

```
from pathlib import Path
import numpy as np
from typing import List
from tqdm.notebook import tqdm
from time import sleep
from PIL import Image
import IPython.display
from sklearn.metrics import balanced_accuracy_score
import gdown
import tensorflow as tf
import matplotlib.pyplot as plt
```

Класс Dataset

Предназначен для работы с наборами данных, обеспечивает чтение изображений и соответствующих меток, а также формирование пакетов (батчей).

In []:

```
class Dataset:

    def __init__(self, name):
        self.name = name
        self.is_loaded = False
        url = f"https://drive.google.com/uc?export=download&confirm=pbef&id={DATASETS_LIN
KS[name]}"
        output = f'{name}.npz'
        gdown.download(url, output, quiet=False)
        print(f'Loading dataset {self.name} from npz.')
        np_obj = np.load(f'{name}.npz')
        self.images = np_obj['data']
        self.labels = np_obj['labels']
        self.n_files = self.images.shape[0]
        self.is_loaded = True
        print(f'Done. Dataset {name} consists of {self.n_files} images.')

    def image(self, i):
        # read i-th image in dataset and return it as numpy array
        if self.is_loaded:
            return self.images[i, :, :, :]

    def images_seq(self, n=None):
        # sequential access to images inside dataset (is needed for testing)
        for i in range(self.n_files if not n else n):
            yield self.image(i)

    def random_image_with_label(self):
        # get random image with label from dataset
        i = np.random.randint(self.n_files)
        return self.image(i), self.labels[i]

    def random_batch_with_labels(self, n, seed=1):
        np.random.seed(seed)
        # create random batch of images with labels (is needed for training)
        indices = np.random.choice(self.n_files, n)
        imgs = []
        for i in indices:
            img = self.image(i)
            imgs.append(self.image(i))
        logits = np.array([self.labels[i] for i in indices])
        return np.stack(imgs), logits
```

```
def image_with_label(self, i: int):  
    # return i-th image with label from dataset  
    return self.image(i), self.labels[i]
```

Пример использования класса **Dataset**

Загрузим обучающий набор данных, получим произвольное изображение с меткой. После чего визуализируем изображение, выведем метку. В будущем, этот кусок кода можно закомментировать или убрать.

In []:


```
d_train_tiny = Dataset('train_tiny')  
  
img, lbl = d_train_tiny.random_image_with_label()  
print()  
print(f'Got numpy array of shape {img.shape}, and label with code {lbl}.')  
print(f'Label code corresponds to {TISSUE_CLASSES[lbl]} class.')
```

pil_img = Image.fromarray(img)
IPython.display.display(pil_img)

Downloading...
From: <https://drive.google.com/uc?export=download&confirm=pbef&id=1I-2ZOuXLd4QwhZQQltp817Kn3J0Xgbui>
To: /content/train_tiny.npz
100%|██████████| 105M/105M [00:00<00:00, 134MB/s]

Loading dataset train_tiny from npz.
Done. Dataset train_tiny consists of 900 images.

Got numpy array of shape (224, 224, 3), and label with code 7.
Label code corresponds to STR class.



Класс **Metrics**

Реализует метрики точности, используемые для оценивания модели:

1. точность,
2. сбалансированную точность.

In []:

```
class Metrics:  
  
    @staticmethod  
    def accuracy(gt: List[int], pred: List[int]):  
        assert len(gt) == len(pred), 'gt and prediction should be of equal length'  
        return sum(int(i[0] == i[1]) for i in zip(gt, pred)) / len(gt)  
  
    @staticmethod  
    def accuracy_balanced(gt: List[int], pred: List[int]):
```

```

        return balanced_accuracy_score(gt, pred)

    @staticmethod
    def print_all(gt: List[int], pred: List[int], info: str):
        print(f'metrics for {info}:')
        print('\t accuracy {:.4f}'.format(Metrics.accuracy(gt, pred)))
        print('\t balanced accuracy {:.4f}'.format(Metrics.accuracy_balanced(gt, pred)))
    )

```

Класс Model

Класс, хранящий в себе всю информацию о модели.

Вам необходимо реализовать методы **save**, **load** для сохранения и загрузки модели. Особенно актуально это будет во время тестирования на дополнительных наборах данных.

Пожалуйста, убедитесь, что сохранение и загрузка модели работает корректно. Для этого обучите модель, протестируйте, сохраните ее в файл, перезапустите среду выполнения, загрузите обученную модель из файла, вновь протестируйте ее на тестовой выборке и убедитесь в том, что получаемые метрики совпадают с полученными для тестовой выборки ранее.

Также, Вы можете реализовать дополнительные функции, такие как:

1. валидацию модели на части обучающей выборки;
2. использование кроссвалидации;
3. автоматическое сохранение модели при обучении;
4. загрузку модели с какой-то конкретной итерации обучения (если используется итеративное обучение);
5. вывод различных показателей в процессе обучения (например, значение функции потерь на каждой эпохе);
6. построение графиков, визуализирующих процесс обучения (например, график зависимости функции потерь от номера эпохи обучения);
7. автоматическое тестирование на тестовом наборе/наборах данных после каждой эпохи обучения (при использовании итеративного обучения);
8. автоматический выбор гиперпараметров модели во время обучения;
9. сохранение и визуализацию результатов тестирования;
10. Использование аугментации и других способов синтетического расширения набора данных (дополнительным плюсом будет обоснование необходимости и обоснование выбора конкретных типов аугментации)
11. и т.д.

Полный список опций и дополнений приведен в презентации с описанием задания.

При реализации дополнительных функций допускается добавление параметров в существующие методы и добавление новых методов в класс модели.

In []:

```

from tensorflow.keras.layers import Input, Conv2D, Activation, MaxPool2D, Flatten, Dense
, Rescaling, RandomFlip, RandomRotation, Dropout, BatchNormalization
from sklearn import svm
from sklearn.model_selection import RandomizedSearchCV, GridSearchCV
from sklearn.utils import shuffle
from sklearn.model_selection import train_test_split
import pickle

```

In []:

```

class Model:

    def __init__(self):
        self.model = tf.keras.Sequential()
        self.model.add(Input(shape=(224, 224, 3)))
        self.model.add(Rescaling(1./255))
        #LBL1 - аугментация

```

```

self.model.add(RandomFlip("horizontal_and_vertical"))
self.model.add(RandomRotation(0.3))

self.model.add(Conv2D(96, (7, 7), padding='same', strides=2, kernel_initializer=
tf.keras.initializers.RandomNormal(stddev=0.01)))
self.model.add(BatchNormalization())
self.model.add(Activation('relu'))
self.model.add(MaxPool2D(pool_size=(3,3), strides=2))
self.model.add(Conv2D(256, (5, 5), strides=2, padding='same', kernel_initializer
=tf.keras.initializers.RandomNormal(stddev=0.01)))
self.model.add(BatchNormalization())
self.model.add(Activation('relu'))
self.model.add(MaxPool2D(pool_size=(3,3), strides=2))

self.model.add(Conv2D(384, (3, 3), padding='same', kernel_initializer=tf.keras.i
nitializers.RandomNormal(stddev=0.01)))
self.model.add(BatchNormalization())
self.model.add(Activation('relu'))
self.model.add(Conv2D(384, (3, 3), padding='same', kernel_initializer=tf.keras.i
nitializers.RandomNormal(stddev=0.01)))
self.model.add(BatchNormalization())
self.model.add(Activation('relu'))
self.model.add(Conv2D(256, (3, 3), padding='same', kernel_initializer=tf.keras.i
nitializers.RandomNormal(stddev=0.01)))
self.model.add(BatchNormalization())
self.model.add(Activation('relu'))

self.model.add(MaxPool2D(pool_size=(3,3), strides=2))
self.model.add(Flatten())

self.model.add(Dense(4096, activation='relu', kernel_initializer=tf.keras.initia
lizers.RandomNormal(stddev=0.01)))
self.model.add(Dropout(0.5))
self.model.add(Dense(4096, activation='relu', kernel_initializer=tf.keras.initia
lizers.RandomNormal(stddev=0.01)))
self.model.add(Dropout(0.5))
self.model.add(Dense(9, kernel_initializer=tf.keras.initializers.RandomNormal(st
ddev=0.01)))
self.model.add(Activation('softmax'))

params = [{
    'C':[0.1, 1, 10, 100],
    'gamma':[0.01, 0.1, 1, 5],
    'kernel':['rbf']
},
{
    'C':[0.1, 1, 10, 100],
    'kernel':['linear']
}]
self.classifier = RandomizedSearchCV(svm.SVC(), params, n_iter=10, cv=4, n_jobs=
2, verbose=2)
self.epochs = 80
self.history = None

def save(self, name: str):
    # example demonstrating saving the model to PROJECT_DIR folder on gdrive with nam
e 'name'
    filename = f'/content/drive/MyDrive/{name}.h5'
    self.model.save_weights(filename, save_format='h5')
    f = open(f'/content/drive/MyDrive/{name}1', 'wb')
    pickle.dump([self.classifier, self.history], f)
    f.close()

def load(self, name: str):
    # example demonstrating loading the model with name 'name' from gdrive using link
name_to_id_dict = {
    'best_cnn': ['1XKw_ta_c8iRrib2MQXNDghE9UcDvVYd9', '1YKr3DQo7M--tjrFBVaxf3kvT
-LzQ9iCy'],
    'best_cnn_1': ['1MSkILgZiBiSpsuxv5xaCoKINtDghraW4', '15wGPXh7VMO5GP_BUpsYgd7nD
XQKHbhyu']
}
    output = f'{name}.h5'

```

```

gdown.download(f"https://drive.google.com/uc?export=download&confirm=pbef&id={name_
e_to_id_dict[name][0]}", output, quiet=False)
self.model.load_weights(output)
output = f'{name}1'
gdown.download(f"https://drive.google.com/uc?export=download&confirm=pbef&id={name_
e_to_id_dict[name][1]}", output, quiet=False)
f = open(output, 'rb')
obj = pickle.load(f)
self.classifier = obj[0]
self.history = obj[1]
f.close()

def train(self, dataset: Dataset, only_classifiers=False):
    print(f'training started')
    batch, batch1, batch_pred, batch_pred1 = train_test_split(dataset.images, dataset.labels, random_state=1147, test_size=0.33)

    if not only_classifiers:
        batch, batch_pred = shuffle(batch, batch_pred)
        batch_pred_new = np.zeros((batch.shape[0], len(TISSUE_CLASSES)))
        for i in range(batch.shape[0]):
            batch_pred_new[i][batch_pred[i]] = 1

        def scheduler(epoch, lr):
            if epoch < 15:
                return lr
            else:
                return lr * tf.math.exp(-0.07)
        #LBL2 - переменный learning rate
        callback = tf.keras.callbacks.LearningRateScheduler(scheduler)
        self.model.compile(optimizer=tf.keras.optimizers.SGD(learning_rate=0.01, momentum=0.9),
                           loss='categorical_crossentropy',
                           metrics = 'accuracy')
        self.history = self.model.fit(batch, batch_pred_new, epochs=self.epochs, batch_size=32, callbacks=[callback])
        print(f'CNN is trained')

        batch1, batch_pred1 = shuffle(batch1, batch_pred1)
        new_batch = np.empty((batch1.shape[0], len(TISSUE_CLASSES)))
        for i in range(batch1.shape[0]):
            new_batch[i] = self.model(batch1[i].reshape((1, 224, 224, 3)), training=False)

        self.classifier.fit(new_batch, batch_pred1)
        print(f'training done')

    def train_visualize(self):
        #LBL3 - визуализация обучения
        acc = self.history.history['accuracy']
        loss = self.history.history['loss']
        epochs_range = np.arange(self.epochs)

        plt.plot(epochs_range, acc, label='Train accuracy', color='b')
        plt.legend()
        plt.title('Accuracy on train')
        plt.grid()
        plt.show()

        plt.plot(epochs_range, loss, label='Train loss', color='r')
        plt.legend()
        plt.title('Loss on train')
        plt.grid()
        plt.show()

    def test_on_dataset(self, dataset: Dataset, limit=None):
        # you can upgrade this code if you want to speed up testing using batches
        predictions = []
        n = dataset.n_files if not limit else int(dataset.n_files * limit)
        for img in tqdm(dataset.images_seq(n), total=n):
            predictions.append(self.test_on_image(img))
        return predictions

```

```
def test_on_image(self, img: np.ndarray):
    img = img.reshape((1, 224, 224, 3))
    prediction = np.array(self.model(img, training=False))
    return self.classifier.predict(prediction)
```

Классификация изображений

Используя введенные выше классы можем перейти уже непосредственно к обучению модели классификации изображений. Пример общего пайплайна решения задачи приведен ниже. Вы можете его расширять и улучшать. В данном примере используются наборы данных **'train_small'** и **'test'**.

In []:

```
d_train = Dataset('train_small')
d_test = Dataset('test')
```

```
Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1qd45xXfDwdZjktLFwQb-et-mAaFeCzOR
To: /content/train_small.npz
100%|██████████| 841M/841M [00:04<00:00, 174MB/s]
```

```
Loading dataset train_small from npz.
Done. Dataset train_small consists of 7200 images.
```

```
Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1RfPou3pFKpuHDJZ-D9XDFzgvwpUBFlDr
To: /content/test.npz
100%|██████████| 525M/525M [00:02<00:00, 194MB/s]
```

```
Loading dataset test from npz.
Done. Dataset test consists of 4500 images.
```

In []:

```
model = Model()
```

In []:

```
if not EVALUATE_ONLY:
    model.train(d_train)
    model.save('best_cnn_1')
else:
    model.load('best_cnn_1')
```

```
Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1MSkILgZiBiSpsuxv5xaCoKINTdGhraW4
To: /content/best_cnn_1.h5
100%|██████████| 233M/233M [00:03<00:00, 76.9MB/s]
Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=15wGPXh7VMO5GP_BUpsYgd7nDXQKHbhyu
To: /content/best_cnn_11
100%|██████████| 467M/467M [00:07<00:00, 59.2MB/s]
```



Визуализация обучения модели:

In []:

In []:

```
In [ ]:
```

```
#LBL3 - визуализация обучения  
model.train_visualize()
```



Пример тестирования модели на части набора данных:

```
In [ ]:
```

```
# evaluating model on 20% of test dataset  
pred_1 = model.test_on_dataset(d_test, limit=0.2)  
Metrics.print_all(d_test.labels[:len(pred_1)], pred_1, '20% of test')
```

```
metrics for 20% of test:  
accuracy 0.9933:  
balanced accuracy 0.9938:
```

```
/usr/local/lib/python3.7/dist-packages/sklearn/metrics/_classification.py:1987: UserWarning: y_pred contains classes not in y_true  
warnings.warn("y_pred contains classes not in y_true")
```

Пример тестирования модели на полном наборе данных:

```
In [ ]:
```

```
# evaluating model on full test dataset (may take time)  
if TEST_ON_LARGE_DATASET:  
    pred_2 = model.test_on_dataset(d_test)  
    Metrics.print_all(d_test.labels, pred_2, 'test')
```

```
metrics for test:  
accuracy 0.9731:  
balanced accuracy 0.9731:
```

```
In [ ]:
```


```
from sklearn.metrics import ConfusionMatrixDisplay
```


Матрица ошибок:

In []:

```
#LBL4 - построение матрицы ошибок
```

```
ConfusionMatrixDisplay.from_predictions(np.array(pred_2).reshape(-1, 1), d_test.labels,
cmap=plt.cm.Blues)
plt.title('Confusion matrix')
plt.show()
```



Результат работы пайплайна обучения и тестирования выше тоже будет оцениваться. Поэтому не забудьте присылать на проверку ноутбук с выполненными ячейками кода с демонстрациями метрик обучения, графиками и т.п. В этом пайплайне Вам необходимо продемонстрировать работу всех реализованных дополнений, улучшений и т.п.

Настоятельно рекомендуется после получения пайплайна с полными результатами обучения экспортировать ноутбук в **pdf** (файл -> печать) и прислать этот **pdf** вместе с самим ноутбуком.

Тестирование модели на других наборах данных

Ваша модель должна поддерживать тестирование на других наборах данных. Для удобства, Вам предоставляется набор данных **test_tiny**, который представляет собой малую часть (**2% изображений**) набора **test**. Ниже приведен фрагмент кода, который будет осуществлять тестирование для оценивания Вашей модели на дополнительных тестовых наборах данных.

Прежде чем отсылать задание на проверку, убедитесь в работоспособности фрагмента кода ниже.

In []:

```
final_model = Model()
final_model.load('best_cnn_1')
d_test_tiny = Dataset('test_tiny')
pred = final_model.test_on_dataset(d_test_tiny)
Metrics.print_all(d_test_tiny.labels, pred, 'test-tiny')
```

Downloading...

From: <https://drive.google.com/uc?export=download&confirm=pbef&id=1MSkILgZiBiSpsuxv5xaCoKINTdGhraW4>

To: /content/best_cnn_1.h5

100%|██████████| 233M/233M [00:01<00:00, 186MB/s]

Downloading...

From: https://drive.google.com/uc?export=download&confirm=pbef&id=15wGPXh7VM05GP_BUpsYgd7nDXQKHbhyu

To: /content/best_cnn_11

100%|██████████| 467M/467M [00:02<00:00, 176MB/s]

Downloading...

From: <https://drive.google.com/uc?export=download&confirm=pbef&id=1viiB0s041CNsAK4itvX8PnYthJ-MDnQc>

To: /content/test_tiny.npz

Loading dataset test_tiny from npz.
Done. Dataset test_tiny consists of 90 images.

metrics for test-tiny:
accuracy 0.9222:
balanced accuracy 0.9222:

Отмонтировать **Google Drive**.

In []:

```
drive.flush_and_unmount()
```

Дополнительные "полезности"

Ниже приведены примеры использования различных функций и библиотек, которые могут быть полезны при выполнении данного практического задания.

Измерение времени работы кода

Измерять время работы какой-либо функции можно легко и непринужденно при помощи функции **timeit** из соответствующего модуля:

In []:

```
import timeit

def factorial(n):
    res = 1
    for i in range(1, n + 1):
        res *= i
    return res

def f():
    return factorial(n=1000)

n_runs = 128
print(f'Function f is caluclated {n_runs} times in {timeit.timeit(f, number=n_runs)}s.')
```

Scikit-learn

Для использования "классических" алгоритмов машинного обучения рекомендуется использовать библиотеку **scikit-learn** (<https://scikit-learn.org/stable/>). Пример классификации изображений цифр из набора данных **MNIST** при помощи классификатора **SVM**:

In []:

```
# Standard scientific Python imports
import matplotlib.pyplot as plt

# Import datasets, classifiers and performance metrics
from sklearn import datasets, svm, metrics
from sklearn.model_selection import train_test_split

# The digits dataset
digits = datasets.load_digits()

# The data that we are interested in is made of 8x8 images of digits, let's
# have a look at the first 4 images, stored in the `images` attribute of the
# dataset. If we were working from image files, we could load them using
```

```

# matplotlib.pyplot.imread. Note that each image must have the same size. For these
# images, we know which digit they represent: it is given in the 'target' of
# the dataset.
_, axes = plt.subplots(2, 4)
images_and_labels = list(zip(digits.images, digits.target))
for ax, (image, label) in zip(axes[0, :], images_and_labels[:4]):
    ax.set_axis_off()
    ax.imshow(image, cmap=plt.cm.gray_r, interpolation='nearest')
    ax.set_title('Training: %i' % label)

# To apply a classifier on this data, we need to flatten the image, to
# turn the data in a (samples, feature) matrix:
n_samples = len(digits.images)
data = digits.images.reshape((n_samples, -1))

# Create a classifier: a support vector classifier
classifier = svm.SVC(gamma=0.001)

# Split data into train and test subsets
X_train, X_test, y_train, y_test = train_test_split(
    data, digits.target, test_size=0.5, shuffle=False)

# We learn the digits on the first half of the digits
classifier.fit(X_train, y_train)

# Now predict the value of the digit on the second half:
predicted = classifier.predict(X_test)

images_and_predictions = list(zip(digits.images[n_samples // 2:], predicted))
for ax, (image, prediction) in zip(axes[1, :], images_and_predictions[:4]):
    ax.set_axis_off()
    ax.imshow(image, cmap=plt.cm.gray_r, interpolation='nearest')
    ax.set_title('Prediction: %i' % prediction)

print("Classification report for classifier %s:\n%s\n"
      % (classifier, metrics.classification_report(y_test, predicted)))
disp = metrics.plot_confusion_matrix(classifier, X_test, y_test)
disp.figure_.suptitle("Confusion Matrix")
print("Confusion matrix:\n%s" % disp.confusion_matrix)

plt.show()

```

Scikit-image

Реализовывать различные операции для работы с изображениями можно как самостоятельно, работая с массивами **numpy**, так и используя специализированные библиотеки, например, **scikit-image** (<https://scikit-image.org/>). Ниже приведен пример использования **Canny edge detector**.

In []:

```

import numpy as np
import matplotlib.pyplot as plt
from scipy import ndimage as ndi

from skimage import feature

# Generate noisy image of a square
im = np.zeros((128, 128))
im[32:-32, 32:-32] = 1

im = ndi.rotate(im, 15, mode='constant')
im = ndi.gaussian_filter(im, 4)
im += 0.2 * np.random.random(im.shape)

# Compute the Canny filter for two values of sigma
edges1 = feature.canny(im)
edges2 = feature.canny(im, sigma=3)

# display results

```

```
fig, (ax1, ax2, ax3) = plt.subplots(nrows=1, ncols=3, figsize=(8, 3),
                                   sharex=True, sharey=True)

ax1.imshow(im, cmap=plt.cm.gray)
ax1.axis('off')
ax1.set_title('noisy image', fontsize=20)

ax2.imshow(edges1, cmap=plt.cm.gray)
ax2.axis('off')
ax2.set_title(r'Canny filter,  $\sigma=1$ ', fontsize=20)

ax3.imshow(edges2, cmap=plt.cm.gray)
ax3.axis('off')
ax3.set_title(r'Canny filter,  $\sigma=3$ ', fontsize=20)

fig.tight_layout()

plt.show()
```

Tensorflow 2

Для создания и обучения нейросетевых моделей можно использовать фреймворк глубокого обучения **Tensorflow 2**. Ниже приведен пример простейшей нейронной сети, использующейся для классификации изображений из набора данных **MNIST**.

In []:

```
# Install TensorFlow

import tensorflow as tf

mnist = tf.keras.datasets.mnist

(x_train, y_train), (x_test, y_test) = mnist.load_data()
x_train, x_test = x_train / 255.0, x_test / 255.0

model = tf.keras.models.Sequential([
    tf.keras.layers.Flatten(input_shape=(28, 28)),
    tf.keras.layers.Dense(128, activation='relu'),
    tf.keras.layers.Dropout(0.2),
    tf.keras.layers.Dense(10, activation='softmax')
])

model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

model.fit(x_train, y_train, epochs=5)

model.evaluate(x_test, y_test, verbose=2)
```

Для эффективной работы с моделями глубокого обучения убедитесь в том, что в текущей среде **Google Colab** используется аппаратный ускоритель **GPU** или **TPU**. Для смены среды выберите "среда выполнения" -> "сменить среду выполнения".

Большое количество туториалов и примеров с кодом на **Tensorflow 2** можно найти на официальном сайте <https://www.tensorflow.org/tutorials?hl=ru>.

Также, Вам может понадобиться написать собственный генератор данных для **Tensorflow 2**. Скорее всего он будет достаточно простым, и его легко можно будет реализовать, используя официальную документацию **TensorFlow 2**. Но, на всякий случай (если не удалось сразу разобраться или хочется вникнуть в тему более глубоко), можете посмотреть следующий отличный туториал: <https://stanford.edu/~shervine/blog/keras-how-to-generate-data-on-the-fly>.

Numba

В некоторых ситуациях, при ручных реализациях графовых алгоритмов, выполнение многократных вложенных циклов **for** в **python** можно существенно ускорить, используя **JIT**-компилятор **Numba** (<https://numba.pydata.org/>). Примеры использования **Numba** в **Google Colab** можно найти тут:

1. https://colab.research.google.com/github/cbernet/maldives/blob/master/numba/numba_cuda.ipynb
2. https://colab.research.google.com/github/evaneschneider/parallel-programming/blob/master/COMPASS_gpu_intro.ipynb

Пожалуйста, если Вы решили использовать **Numba** для решения этого практического задания, еще раз подумайте, нужно ли это Вам, и есть ли возможность реализовать требуемую функциональность иным способом. Используйте **Numba** только при реальной необходимости.

Работа с zip архивами в Google Drive

Запаковка и распаковка **zip** архивов может пригодиться при сохранении и загрузки Вашей модели. Ниже приведен фрагмент кода, иллюстрирующий помещение нескольких файлов в **zip** архив с последующим чтением файлов из него. Все действия с директориями, файлами и архивами должны осущетвляться с примонтированным **Google Drive**.

Создадим **2** изображения, поместим их в директорию **tmp** внутри **PROJECT_DIR**, запакуем директорию **tmp** в архив **tmp.zip**.

In []:

```
PROJECT_DIR = "/dev/prak_nn_1/"
arr1 = np.random.rand(100, 100, 3) * 255
arr2 = np.random.rand(100, 100, 3) * 255

img1 = Image.fromarray(arr1.astype('uint8'))
img2 = Image.fromarray(arr2.astype('uint8'))

p = "/content/drive/MyDrive/" + PROJECT_DIR

if not (Path(p) / 'tmp').exists():
    (Path(p) / 'tmp').mkdir()

img1.save(str(Path(p) / 'tmp' / 'img1.png'))
img2.save(str(Path(p) / 'tmp' / 'img2.png'))

%cd $p
!zip -r "tmp.zip" "tmp"
```

Распакуем архив **tmp.zip** в директорию **tmp2** в **PROJECT_DIR**. Теперь внутри директории **tmp2** содержится директория **tmp**, внутри которой находятся **2** изображения.

In []:

```
p = "/content/drive/MyDrive/" + PROJECT_DIR
%cd $p
!unzip -uq "tmp.zip" -d "tmp2"
```